AIラベリングの修正ループ

ラベルを固定せず、修正を繰り返す前提で記録・学習・評価する設計（lab-research-notes 2026-10-21 のノートから）

結論

設計の要点は3つ

ラベルを固定せず、修正を繰り返す前提で記録・学習・評価する

1 **観測と判定の2層に分ける**
観測＝何が写っているかの票（LLM/VLM に複数回、属性ごとに yes／maybe／no）。判定＝版付きの規則で観測から機械的に導く最終カテゴリ

2 **ラベルは上書きせず、追記する**
出来事として残し、「現在のラベル」は指定した規則版での最新の出来事というビュー

3 **曖昧はクラスではなく状態**
投票分布をそのまま教師に使い、残った曖昧群は規則を足す候補にする

出典: lab-research-notes「AIラベリングで修正をループに組み込む設計」(2026-10-21)

観測と判定を分ける

LLM/VLM には何が写っているかだけを答えさせ、カテゴリは版付きの規則で観測から導く



- 専門家が書いた規則群（ラベル関数）の出力で学習すると、大規模な手ラベルで学習した場合との差は平均3.6%

出典: Snorkel（VLDB 2017）。3.6%は同論文の評価の平均

設計

基準の変更は規則の再導出で済む

LLM/VLM に問い合わせ直すのは、観測の項目を足すときだけ

判定の基準を変える

規則の版を上げる

保存済みの観測から全件を導き直す

判定が変わる件を報告する

観測の項目を足す

LLM/VLM に問い合わせ直す

足した項目だけでよい

- 基準をラベラー（ラベルを付ける LLM/VLM）に暗黙に当てはめさせると、基準を変えるたびに全件を付け直すことになる

設計

上書きせず、追記する

ラベルは出来事の列として残し、「現在のラベル」は指定した規則版での最新の出来事を引くビューにする

誰が・何で

モデル版

プロンプトのハッシュ

何を見たか

投票（属性ごとの yes／maybe／no）

1文の理由

どう決めたか

規則版

発火した規則ID

どこから来たか

親の出来事（修正元）

曖昧は状態として扱う

「曖昧」クラスは作らず、票が割れた状態のまま持つ

教師にする
投票の分布をそのままソフトラベルに使う

→

一度だけ上げる
上位のラベラー（より強いモデルや人）に一度だけ判定させる

→

規則の候補にする
それでも割れた曖昧群をクラスタにまとめ、規則を足す候補にする

- 文献では、人の票の分布で学習すると分布外への汎化と頑健性が上がり、ばらつきはノイズでなく信号で、分布をそのまま使う単純な方法が複雑な手法を上回る

出典: CIFAR-10H（ICCV 2019）、Plank（EMNLP 2022）、Uma ら（JAIR 2021）。LLM の少数票では未検証（付録）

設計

固定するのは3つのID

ラベルは後から直されて変わるので、使うデータはラベルでなく3つのIDの組で指す

画像集合ID
どの画像か

規則版
どの規則で判定したか

スナップショットID
ラベルの記録をいつ切り出したか

- モデルの予測を保存しておけば、ラベルが直されて新しいスナップショットができても、過去のモデルを推論し直さずに採点し直せる

運用

修正を始める4つの引き金

どの引き金でも、全件を LLM/VLM に問い合わせ直すことにはならない

基準変更

規則を直して全件を導き直す

変わった件を報告する

誤り検出

分類器の予測確率とラベルの食い違いで候補を出す

ランダム監査で誤り率を推定する

ラベラーの版更新

固定の校正標本で新旧の一致率を測ってから切り替える

全件は付け直さない

曖昧の解消

票が割れた画像をクラスタにまとめる

規則案にする

出典: 誤り検出は confident learning（JAIR 2021、cleanlab）

運用

人手は3箇所に絞る

観測の付与と判定の再導出は機械が行い、人が見るのはこの3箇所だけ

監査標本

層化ランダムに抜いた画像を人が確かめ、ラベルの誤り率を推定する

票割れの調停

票が割れた画像を、対立する候補を並べて人が決める。推奨は1つに絞って示さない

規則の採否

曖昧群から出た規則案を採るかどうかを人が決める

評価

AIラベルの統計は壊れやすい

AIラベルから出した統計は、最上位モデルでも約3割の仮説で結論を誤る

結論が誤った仮説の割合（LLM hacking、最上位モデル、テキスト注釈での結果）

約31%

少数の人ラベルで PPI／DSL の補正をすると、妥当な信頼区間が出る

出典: LLM hacking、PPI++、DSL（正式名は付録）

評価は3つの指標で見る

曖昧な画像が残る前提なので、精度を1つの数字にしない

区分	指標	何を見るか
基本	厳密精度	票がそろった画像で、予測がラベルと一致した割合
基本	許容集合精度	全件で、予測が許容ラベル集合（しきい値を超えた票のラベル）に入った割合
基本	曖昧率	票が割れた画像の割合
追加	希少型のリコール	少ない型を取りこぼしていないか

- 品質不能・対象外は別フラグで分母から外し、件数を報告する

出典: 許容ラベル集合は ImageNet ReaL 方式

限界

やらないこと3つ

読み返したら、今の設計がこの3つに当たっていないかを確かめる

やらないこと		代わりにやること
最終ラベルだけを保存する	→	投票・規則の版・理由を出来事として追記する
基準をラベラー（LLM/VLM）に暗黙に当てはめさせる	→	写っているものだけを問い、カテゴリは規則で導く
maybe（どちらとも言えない票）をノイズとして捨てる	→	票の分布をそのまま教師に使う

LLMをラベラーにするときの3点

版

同じサービスでも、版が変わると振る舞いが短期間で大きく変わる

GPT-4 の2023年3月版と6月版

理由

理由を先に説明させてから付けさせると品質が上がる

検証器が採点し、低い点だけ付け直す協調型もある

系統

LLMの判定者は同系統の出力を高く評価する

本番の委譲先とラベラーを同系統にしない

出典: GPT-4 の2023年3月版と6月版の比較、AnnoLLM、CHI 2024 の協調型アノテーション、preference leakage

未確認のこと

1 **ソフトラベル学習の効果**
効果は人の投票で示されたもの。LLM の少数票で同じかは未検証

2 **「主要被写体」の判断**
観測と判定の境界にあり、基準の影響を完全には逃れない

- このノートは文献調査の結果で、手元のデータでの実測は含まない

出典

文献（リンク先が原文）
Snorkel
Confident Learning（cleanlab）
CIFAR-10H
The “Problem” of Human Label Variation
Learning from Disagreement（survey）
How Is ChatGPT’s Behavior Changing over Time?

文献（リンク先が原文）
AnnoLLM
Human-LLM Collaborative Annotation（CHI 2024）
ImageNet ReaL ／ github.com
LLM hacking
PPI++ ／ DSL
Preference leakage（自己選好）